Final Ingeniería de Datos – AWS

Dylan Alexander Mejía Ceballos

Despliegue



```
aws_s3_bucket.datos: Creation complete after 3s [id=de-final-entregas-145295679723]
aws_s3_bucket_public_access_block.datos: Creating...
aws_s3_bucket_ownership_controls.datos: Creating...
aws_s3_object.prefijo_entregas: Creating...
aws_s3_bucket_server_side_encryption_configuration.datos: Creating...
aws_s3_object.prefijo_resultados: Creating...
aws_athena_workgroup.entregas: Creating...
aws_glue_catalog_table.entregas: Creating...
aws_s3_bucket_public_access_block.datos: Creation complete after 1s [id=de-final-entregas-145295679723]
aws_s3_bucket_ownership_controls.datos: Creation complete after 1s [id=de-final-entregas-145295679723]
aws_glue_catalog_table.entregas: Creation complete after 1s [id=145295679723:entregas_db:entregas]
aws_s3_object.prefijo_resultados: Creation complete after 1s [id=resultados-athena/]
aws_s3_object.prefijo_entregas: Creation complete after 1s [id=entregas/]
aws_s3_bucket_server_side_encryption_configuration.datos: Creation complete after 2s [id=de-final-entregas-145295679723]
aws_athena_workgroup.entregas: Creation complete after 2s [id=entregas_wg]

Apply complete! Resources: 9 added, 0 changed, 0 destroyed.

Outputs:

base_datos = "entregas_db"
bucket = "de-final-entregas-145295679723"
bucket_arn = "arn:aws:s3:::de-final-entregas-145295679723"
region = "us-east-1"
ruta_entregas = "s3://de-final-entregas-145295679723/entregas/"
ruta_resultados_athena = "s3://de-final-entregas-145295679723/resultados-athena/"
tabla = "entregas"
workgroup = "entregas_wg"
```

Se aplica Terraform: Apply complete! Resources: 9 added y los outputs del bucket, la base de datos, la tabla y el workgroup

Etapa inicial (días 1 y 2)



```
diff resultados/inicial/intentos_por_fecha_estado.csv resultados_esperados/intentos_por_fecha_estado_inicial.csv && echo OK1
de-final-entregas-145295679723
{
    "skip.header.line.count": "1",
    "projection.fecha.format": "yyyy-MM-dd",
    "projection.fecha.interval.unit": "DAYS",
    "EXTERNAL": "TRUE",
    "projection.fecha.range": "2026-10-01,2026-10-03",
    "classification": "csv",
    "projection.fecha.interval": "1",
    "projection.enabled": "true",
    "projection.fecha.type": "date",
    "storage.location.template": "s3://de-final-entregas-145295679723/entregas/fecha=${fecha}/"
}
{
    "Partitions": []
}
upload: data/entregas/fecha=2026-10-01/entregas.csv to s3://de-final-entregas-145295679723/entregas/fecha=2026-10-01/entregas.csv
upload: data/entregas/fecha=2026-10-02/entregas.csv to s3://de-final-entregas-145295679723/entregas/fecha=2026-10-02/entregas.csv
2026-11-12 07:13:45          0 entregas/
2026-11-12 07:20:38        313 entregas/fecha=2026-10-01/entregas.csv
2026-11-12 07:20:40        313 entregas/fecha=2026-10-02/entregas.csv
Ejecucion: 2fd12621-9014-4f69-8dce-8dd1acb734ae
Resultado guardado en resultados/inicial/intentos_por_fecha_estado.csv:
fecha,estado,total_intentos
2026-10-01,destinatario_ausente,2
2026-10-01,direccion_incorrecta,1
2026-10-01,entregado,3
2026-10-02,destinatario_ausente,1
2026-10-02,direccion_incorrecta,2
2026-10-02,entregado,3
OK1
```

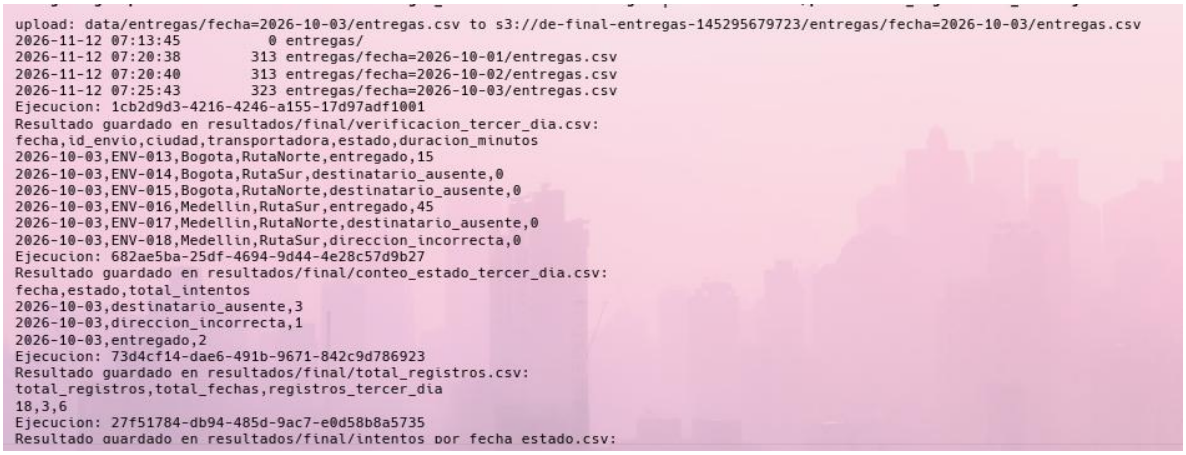
Etapa inicial. Se verifica la tabla entregas: tiene partition projection habilitado (projection.enabled = true, tipo date, formato yyyy-MM-dd, rango 2026-10-01,2026-10-03, intervalo de 1 día y plantilla entregas/fecha=${fecha}/) y no tiene particiones registradas en Glue ("Partitions": []).

Se cargan individualmente solo los archivos del 1 y del 2 de octubre en S3. La consulta de intentos por fecha y estado (ejecución 2fd12621-9014-4f69-8dce-8dd1acb734ae) devuelve 6 filas, idénticas a resultados_esperados/intentos_por_fecha_estado_inicial.csv (OK1).



Etapa inicial (días 1 y 2): porcentaje de éxito por fecha y ciudad (ejecución 5a315118-...) y duración promedio de las entregas exitosas del 2026-10-02 = 36.67 min (ejecución 2c752049-...). Ambos resultados coinciden con las referencias (OK2, OK3). ejecuciones_athena.csv registra las 3 ejecuciones de la etapa inicial.

Etapa final (día 3)

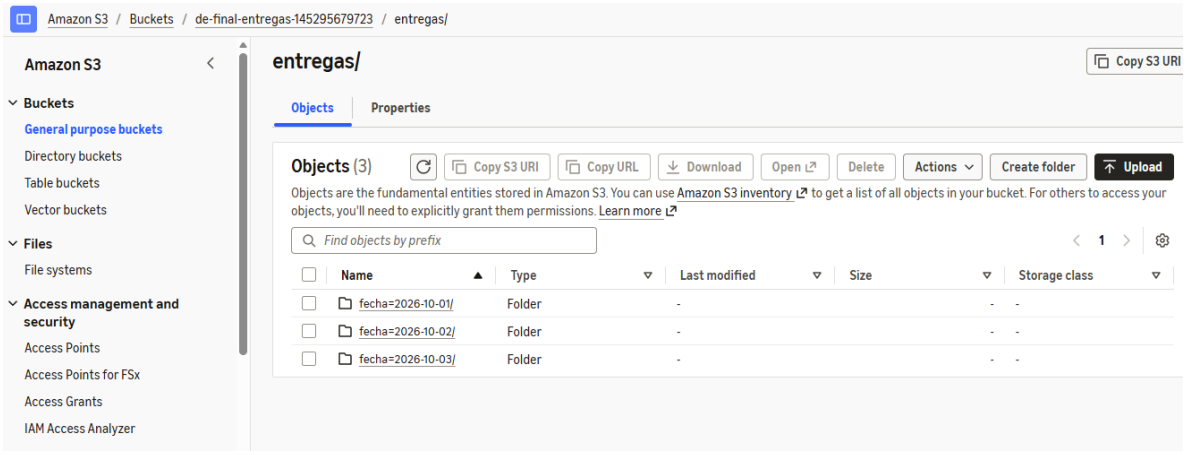




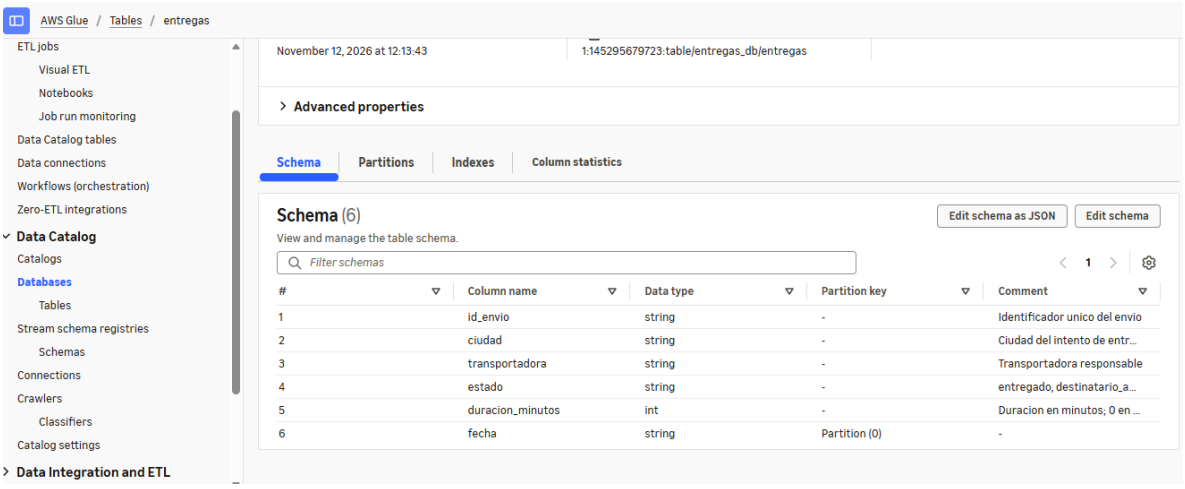
Etapa final. Sin modificar Terraform ni la tabla, sin crawlers, sin MSCK REPAIR y sin ALTER TABLE ADD PARTITION, solo se sube fecha=2026-10-03/entregas.csv. Athena lee los 6 registros del día 3 (ejecución 1cb2d9d3-...), con conteos por estado de 3 ausentes, 1

dirección incorrecta y 2 entregados (682ae5ba-...). La tabla suma 18 registros en 3 fechas (73d4cf14-...). Las consultas agregadas incluyen el tercer día y coinciden con las referencias finales (OK4, OK5). Glue sigue sin particiones registradas ("Partitions": []): el día 3 se resolvió con partition projection.

Verificación en la consola de AWS



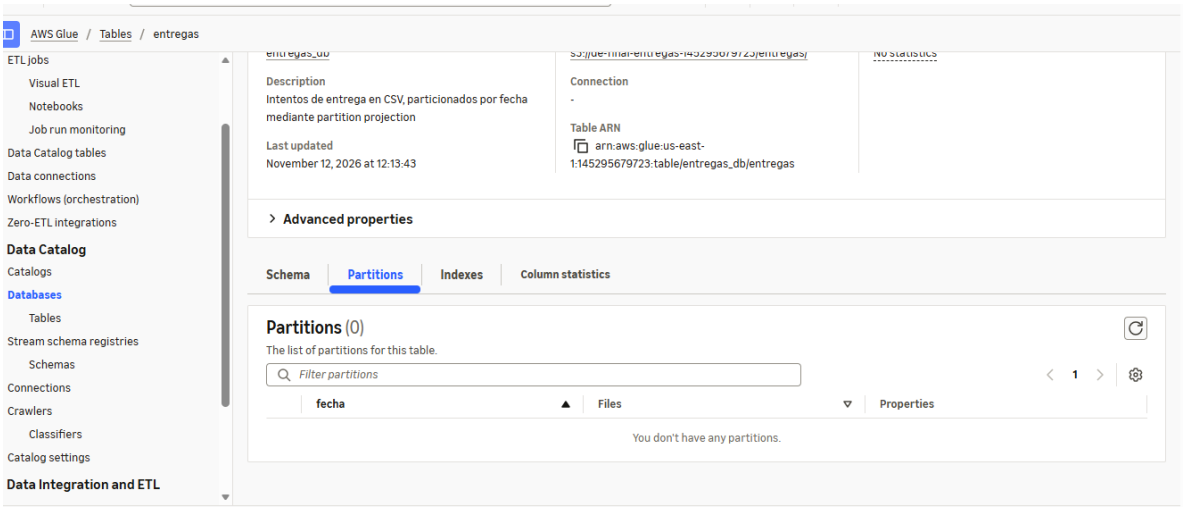
Prefijo entregas/ del bucket privado de-final-entregas-145295679723 al finalizar la demostración. Contiene una carpeta por fecha (fecha=2026-10-01/, fecha=2026-10-02/ y fecha=2026-10-03/), cada una con su entregas.csv, en la ruta que espera la plantilla entregas/fecha=${fecha}/ de la tabla. Los días 1 y 2 se cargaron en la etapa inicial y el día 3 después, archivo por archivo y sin carga recursiva. Los resultados de Athena se guardan en otro prefijo, resultados-athena/.



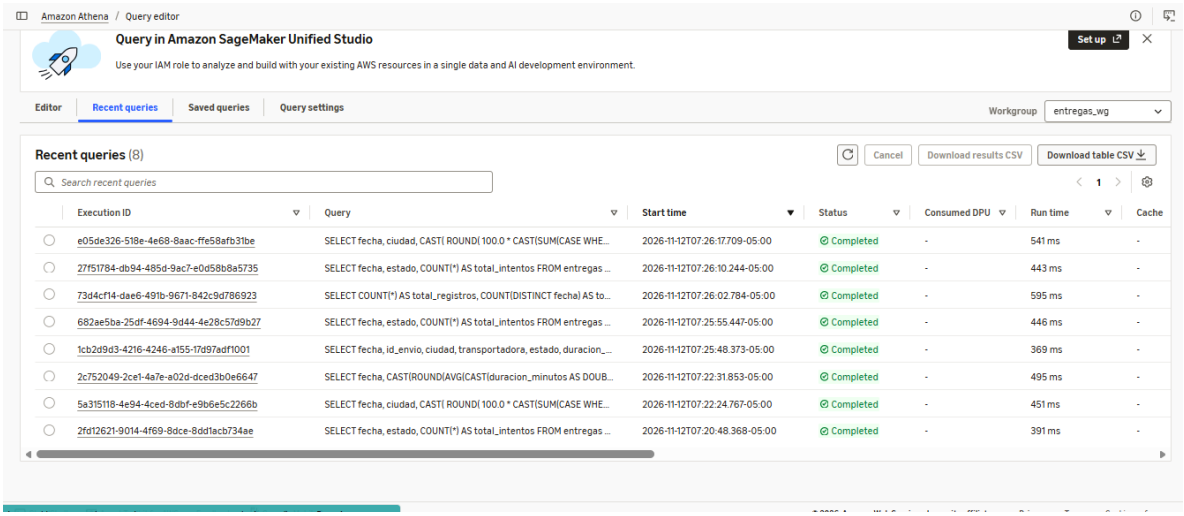
Esquema de la tabla externa entregas_db.entregas en Glue Data Catalog. Tiene las cinco columnas del CSV en el orden del diccionario (id_envio, ciudad, transportadora y estado como string; duracion_minutos como int) y fecha (string) como clave de partición, separada de las columnas del archivo. *Partition (0)* indica que es la primera y única clave de partición, no la cantidad de particiones.



Propiedades de la tabla definidas en Terraform: partition projection habilitado para fecha (tipo date, formato yyyy-MM-dd, rango 2026-10-01,2026-10-03, intervalo de 1 día) y plantilla de ubicación s3://.../entregas/fecha=${fecha}/. También se omite el encabezado (skip.header.line.count = 1).

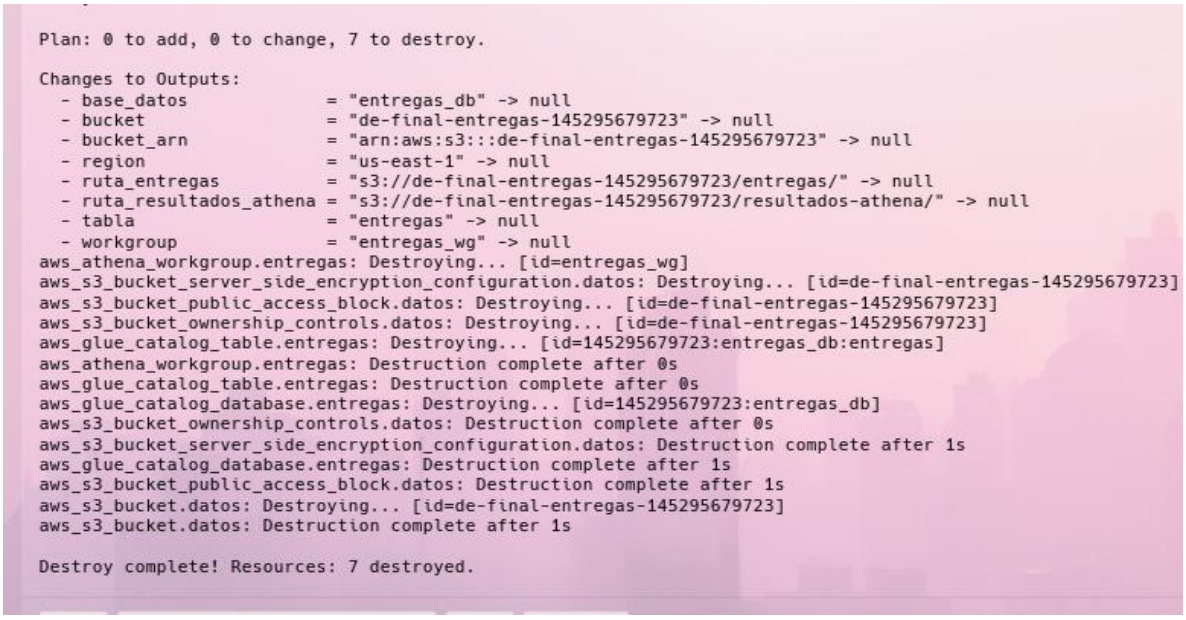


La tabla no tiene particiones registradas en el catálogo, aunque Athena leyó los tres días (18 registros). Las fechas se resuelven en tiempo de consulta mediante partition projection, sin crawlers ni ADD PARTITION.



Historial del workgroup entregas_wg en Athena: las 8 consultas del ejercicio, todas en estado *Completed*. Las 3 primeras (de 07:20 a 07:22) son de la etapa inicial, con los días 1 y 2. Las 5 siguientes (de 07:25 a 07:26) son de la etapa final, después de subir el día 3: verificación de registros, conteo por estado, total, intentos y porcentaje de éxito. Los Execution ID corresponden a los registrados en evidencias/ejecuciones_athena.csv.

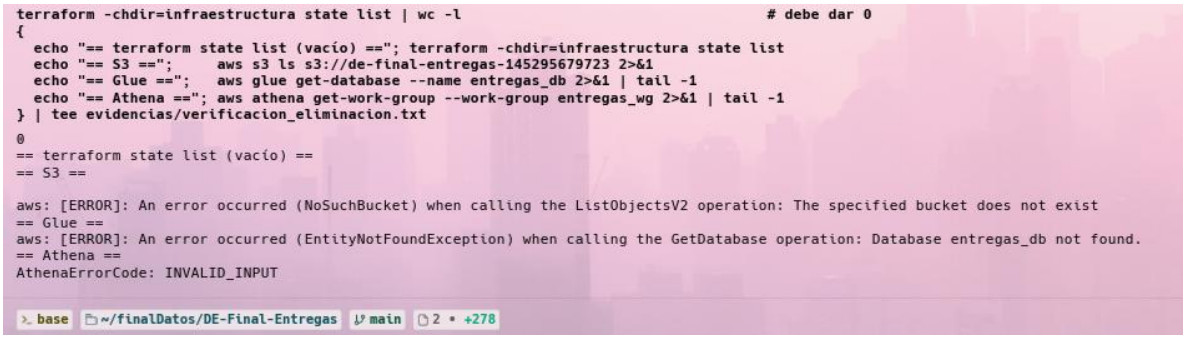
Limpieza



```
Plan: 0 to add, 0 to change, 7 to destroy.

Changes to Outputs:
  - base_datos             = "entregas_db" -> null
  - bucket                 = "de-final-entregas-145295679723" -> null
  - bucket_arn             = "arn:aws:s3:::de-final-entregas-145295679723" -> null
  - region                 = "us-east-1" -> null
  - ruta_entregas          = "s3://de-final-entregas-145295679723/entregas/" -> null
  - ruta_resultados_athena = "s3://de-final-entregas-145295679723/resultados-athena/" -> null
  - tabla                  = "entregas" -> null
  - workgroup              = "entregas_wg" -> null
aws_athena_workgroup.entregas: Destroying... [id=entregas_wg]
aws_s3_bucket_server_side_encryption_configuration.datos: Destroying... [id=de-final-entregas-145295679723]
aws_s3_bucket_public_access_block.datos: Destroying... [id=de-final-entregas-145295679723]
aws_s3_bucket_ownership_controls.datos: Destroying... [id=de-final-entregas-145295679723]
aws_glue_catalog_table.entregas: Destroying... [id=145295679723:entregas_db:entregas]
aws_athena_workgroup.entregas: Destruction complete after 0s
aws_glue_catalog_table.entregas: Destruction complete after 0s
aws_glue_catalog_database.entregas: Destroying... [id=145295679723:entregas_db]
aws_s3_bucket_ownership_controls.datos: Destruction complete after 0s
aws_s3_bucket_server_side_encryption_configuration.datos: Destruction complete after 1s
aws_glue_catalog_database.entregas: Destruction complete after 1s
aws_s3_bucket_public_access_block.datos: Destruction complete after 1s
aws_s3_bucket.datos: Destroying... [id=de-final-entregas-145295679723]
aws_s3_bucket.datos: Destruction complete after 1s

Destroy complete! Resources: 7 destroyed.
```



```
terraform -chdir=infraestructura state list | wc -l                                  # debe dar 0
{
  echo "== terraform state list (vacío) =="; terraform -chdir=infraestructura state list
  echo "== S3 ==";     aws s3 ls s3://de-final-entregas-145295679723 2>&1
  echo "== Glue ==";   aws glue get-database --name entregas_db 2>&1 | tail -1
  echo "== Athena ==" ; aws athena get-work-group --work-group entregas_wg 2>&1 | tail -1
} | tee evidencias/verificacion_eliminacion.txt
0
== terraform state list (vacío) ==
== S3 ==

aws: [ERROR]: An error occurred (NoSuchBucket) when calling the ListObjectsV2 operation: The specified bucket does not exist
== Glue ==
aws: [ERROR]: An error occurred (EntityNotFoundException) when calling the GetDatabase operation: Database entregas_db not found.
== Athena ==
AthenaErrorCode: INVALID_INPUT

base ~/finalDatos/DE-Final-Entregas main 2 • +278
```

Se vació el bucket (aws s3 rm --recursive, que eliminó los datos, los resultados de Athena y los marcadores de prefijo) y se ejecutó terraform destroy: Destroy complete! Resources: 7 destroyed. Terraform reporta 7 y no 9 porque los dos objetos de prefijo ya se habían borrado al vaciar el bucket. La verificación posterior confirma que el bucket, la base de datos de Glue (con su tabla) y el workgroup de Athena ya no existen (evidencias/verificacion_eliminacion.txt).

Respuestas

1. ¿Por qué se pudo consultar el tercer día sin registrar una partición nueva?

La proyección ya incluía el día 3 desde que se hizo el apply al principio de todo, y athena calcula la ruta en cada consulta, antes no había archivo, cuando lo subí se leyó y paso a 18.

Esto se ve en como no hay particiones y hay 18 registros.

2. ¿Qué pasaría con un archivo del 4 de octubre manteniendo la configuración actual?

El 4 de Octubre esta fuera del rango, por eso da 0 filas sin error alguno, para incluirlo hay que cambiar la fecha fin en Terraform, hacer el apply y ampliar la query between en sql.